LMSYS - Chatbot Arena Human Preference Predictions

Overview

这项比赛要求您在由大型语言模型 (LLM) 驱动的聊天机器人之间的正面对决中预测用户会喜欢哪些回答。您将获得来自 Chatbot Arena 的对话数据集，其中不同的 LLM 会生成对用户提示的回答。通过开发成功的机器学习模型，您将帮助改善聊天机器人与人类的互动方式，并确保它们更好地符合人类的偏好。

Evaluation

提交的内容将根据预测概率和真实值之间的对数损失进行评估。

Log Loss，也称为对数损失或交叉熵损失（Cross-Entropy Loss），是一种在机器学习中用于评估分类模型性能的损失函数，特别是在处理多类分类问题时。它衡量的是模型预测的概率分布与真实标签的概率分布之间的差异。

> 对于一个给定的样本，假设其真实标签为 (y)，模型预测的概率分布为 (p)，Log Loss 可以通>过以下公式计算：
>
> $$\text{Log Loss} = -\frac{1}{N}\sum_{i=1}^{N}\sum_{j=1}^{M} y_{ij} > \log(p_{ij})$$
>
> 参数解释:
>
> - N是样本的总数。
> - M是类别的总数。
> - y_{ij}是一个二进制指示器（0或1），如果样本 i 属于类别 j，则为1，否则为0。
> - p_{ij}是模型预测样本 i 属于类别 j 的概率。
> - log通常是以自然对数为底的对数。

Log Loss 能够给予错误分类更高的惩罚，特别是当预测概率远离真实标签时。这促使模型生成更准确的预测概率，而不仅仅是预测正确的类别。Log Loss 常用于逻辑回归和神经网络等模型的优化中。

Dataset Description

竞赛数据集由 ChatBot Arena 中的用户交互组成。在每次用户交互中，评委向两个不同的大型语言模型提供一个或多个提示，然后指出哪个模型给出了更令人满意的响应。竞赛的目标是预测评委的偏好，并确定给定的提示/响应对被选为获胜者的可能性。请注意，这是一场代码竞赛。当您的提交被评分时，此示例测试数据将替换为完整测试集。训练数据中有 55K 行，测试集中大约有 25,000 行。

Files

train.csv

- `id` - A unique identifier for the row.
- `model_[a/b]` - The identity of model_[a/b]. Included in train.csv but not test.csv.
- `prompt` - The prompt that was given as an input (to both models).

- `response_[a/b]` - The response from model_[a/b] to the given prompt.
- `winner_model_[a/b/tie]` - Binary columns marking the judge's selection. The ground truth target column.

test.csv

- `id`
- `prompt`
- `response_[a/b]`

sample_submission.csv A submission file in the correct format.

- `id`
- `winner_model_[a/b/tie]` - This is what is predicted from the test set.

Model

BERT

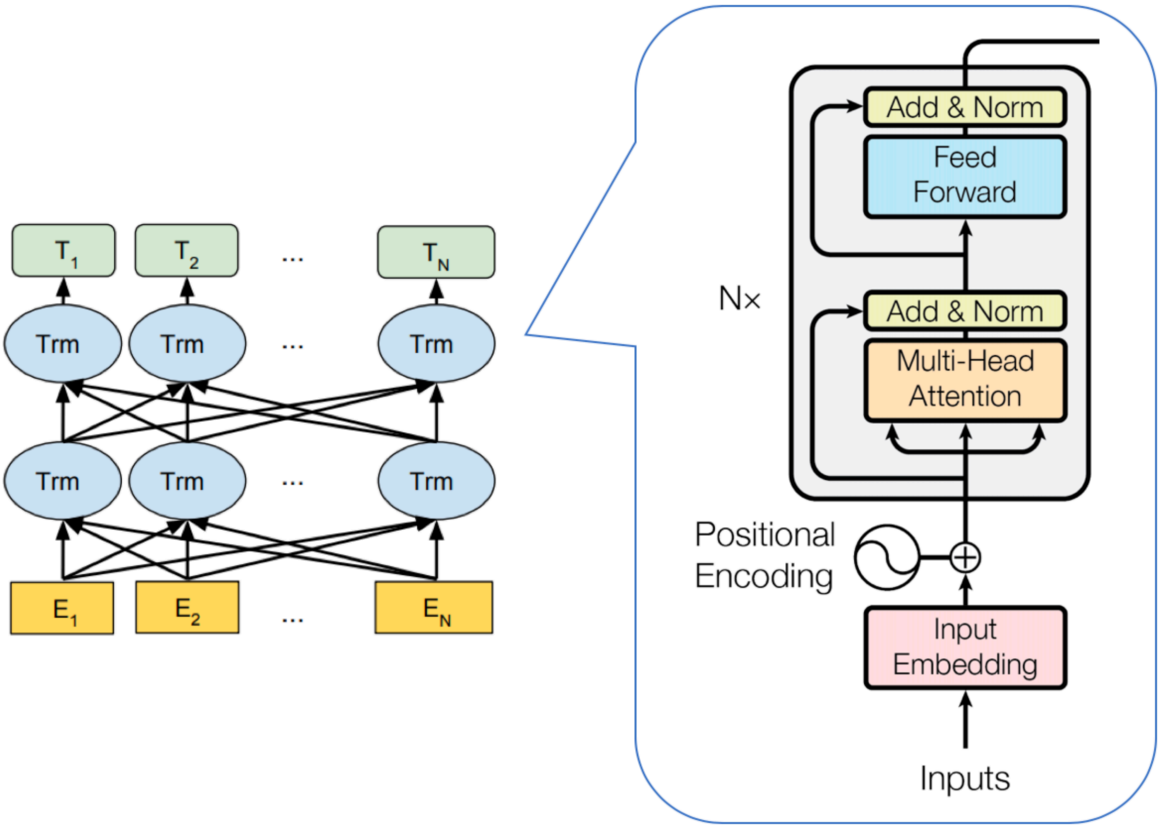

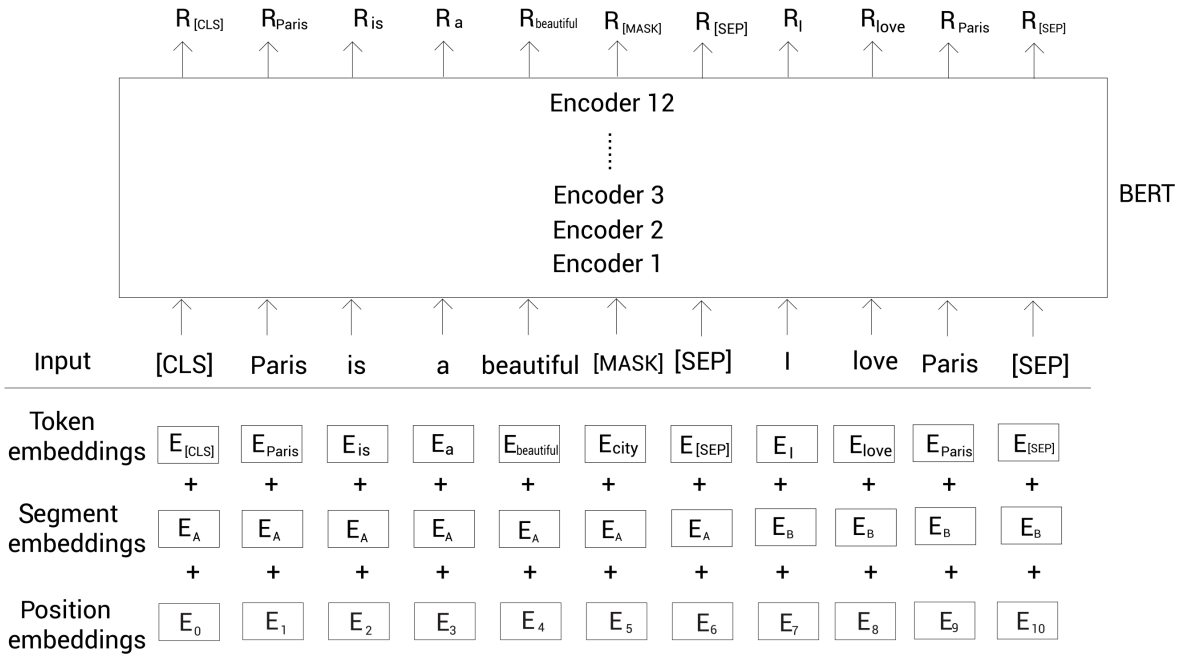

DeBERTa

DeBERTa 模型使用了两种新技术改进了 BERT 和 RoBERTa 模型，同时还引入了一种新的微调方法以提高模型的泛化能力。

> RoBERTa模型（Robustly Optimized BERT Approach）
> 概述：
> RoBERTa（Robustly Optimized BERT Approach）是由Facebook AI于2019年提出的一种BERT模型的改进版本。RoBERTa通过对BERT的训练过程进行优化，进一步提升了模型的性能。
>
> 工作原理：
>
> - 更大的数据集和更长的训练时间：RoBERTa在更大的数据集上进行了更长时间的预训练，确保模型能够学习到更多的语言知识。
> - 去掉Next Sentence Prediction任务：BERT在预训练时包括两个任务：掩码语言模型和下一句预测（Next Sentence Prediction, NSP）。RoBERTa发现NSP任务对模型性能提升有限，因此在预训练中去掉了NSP任务，只保留MLM任务。
> - 动态掩码：RoBERTa在每个训练周期动态生成掩码，而不是像BERT那样在训练开始前就固定掩码位置。这种方法增加了训练数据的多样性，提高了模型的泛化能力。

两种新技术的改进：

- **注意力解耦机制**：DeBERTa采用拆分注意力机制，每个词由两个向量表示其内容和位置信息。词对之间的注意力权重通过分离矩阵计算内容和相对位置信息。
- **增强的掩码解码器**：DeBERTa在解码层中引入词的绝对位置嵌入，用于MLM预训练任务中的掩盖词预测。

新的微调方法：**虚拟对抗训练方法。**

- 虚拟对抗训练通过在输入数据上添加小扰动，使模型在面对稍微变化的输入时仍能保持稳定的输出，提高模型的鲁棒性。

> 我们使用了Keras框架的Bert模型的变体`deberta_v3_extra_small_en`，参数为70.86M，12 层 DeBERTaV3 模型，其中外壳保持不变。接受过英语维基百科、BookCorpus 和 OpenWebText 的训练。

Code

`环境：kaggle notebook`

使用 KerasNLP 的共享权重策略微调本次比赛的 DebertaV3 模型。

> **共享权重策略**：在不同的任务或模型部分之间共享权重，以利用不同任务之间的相关性，提高模型的效率和泛化能力。

Import Libraries

```
os.environ["KERAS_BACKEND"]
```

- Python用于设置环境变量的一种方式。在这种情况下，它被用来指定Keras后端，即Keras在执行其操作时所依赖的底层计算库。

> Keras是一个高级神经网络API，它允许用户快速构建和训练深度学习模型。Keras本身不执行计算，而是依赖于后端库来执行这些操作。Keras支持多种后端，包括TensorFlow、Theano、CNTK等。这些后端提供了底层的计算能力，使得Keras能够执行复杂的数学运算Import。

Prompt and Responses

有 14 行重复，形成 7 组，我们只保留每组一行。

```
df = df.drop_duplicates(keep="first", ignore_index=True)
```

我们检查这三列中是否有任何缺失值，由于每个条目都以字符串 类型 表示，因此我们需要事先调用 eval()。可以看出，eval() 对两个响应列都失败，因为无法处理 null。

- `eval(x)` 是 Python 中的一个内置函数，它用于动态执行字符串形式的表达式，并返回表达式的结果。这个函数会将传入的字符串 `x` 作为一个有效的 Python 表达式进行求值，并返回其计算结果。

```
for col in ["prompt", "response_a", "response_b"]:
try:
  train[col] = train[col].apply(lambda x: eval(x))
except Exception as e:
  print(f"eval() fails for column {col}...")
  print(f"Error: {e}")
```

```
eval() fails for column response_a...
Error: name 'null' is not defined
eval() fails for column response_b...
Error: name 'null' is not defined
```

如果至少有一个响应为空，而不是“null”，则 eval() 会失败。为了解决这个问题，我们只需将 null 替换为 None，一切就都正常了！

```
for col in ["prompt"]:
 df[col] = df[col].apply(lambda x: eval(x))
 test_df[col] = test_df[col].apply(lambda x: eval(x))
for col in ["response_a", "response_b"]:
 df[col] = df[col].apply(lambda x: eval(x.replace("null", "None")))
 test_df[col] = test_df[col].apply(lambda x: eval(x.replace("null",
"None")))
```

Contextualize Response with Prompt

我们将使用提示语境化每个响应，而不是对所有响应使用单个提示。这意味着对于每个响应，我们将为模型提供同一组提示及其各自的响应（例如，（P + R_A），（P + R_B）等）。

- 某些提示和响应可能包含无法识别的Unicode字符，从而导致创建数据加载器时出错。在这种情况下，我们将用空字符串替换它们。

```
# 文本清洗，例如去除无法识别的Unicode字符或替换它们
clean_response_a_str = "".join(filter(lambda x: ord(x) < 128,
response_a_str))
clean_response_a_str = "".join(filter(lambda x: ord(x) < 128,
response_b_str))
```

EDA

Number of Turns

- 86.88% 的对话是单轮对话。
- 超过 99.19% 的对话少于 6 轮。
- 最大轮次数为 36。

Response Length

> LLM 和人类的冗长偏见（即 LLM 和人类有时喜欢较长的答案，即使质量没有提高）

- 回应长度的分布同样呈现右偏，意味着较长回应的样本较少。
- 两个模型的回应长度分布存在差异，尤其是在平均长度和最大长度上。

Pair Length Relationship

- 分析了模型A和B的回应长度之间的关系，以及提示长度与回应长度之间的关系。
- 发现两个模型的回应长度之间存在强正相关，可能是因为两个模型都接收到相同的提示。
- 提示长度与回应长度之间的相关性则显得较弱。

Verbosity Bias

- 探讨了LLMs和人类评判者是否存在偏好更长回答的倾向，即使回答的质量并未提高。
- 通过分析回应长度差异与评判者选择的关系，发现当模型B的回应比模型A长时，评判者倾向于选择模型B。
- 通过创建更细粒度的区间，发现在`(-1, 0]`区间内，平局的概率超过0.7，这表明数据集中存在冗余性偏好。
- **创建长度差异区间（Buckets）**将回应长度差异分为不同的区间，以更细致地观察不同区间内评判者的偏好。当创建更细粒度的区间时，注意到在区间(-1, 0]内，平局的概率超过了0.7。这表明在这个区间内，评判者很难区分哪个模型的回答更好，即两个模型的回答长度差异不大时，评判者倾向于认为是平局。

Feature

最终我们提取了以下的特征，先做归一化处理最后作为数值特征嵌入文本向量中

```
numerical_feature_columns =
["res_a_len_sum","res_a_len_mean","res_a_len_max","res_a_len_sum_log","res_a_len_
mean_log","res_a_len_max_log","res_a_len_med","res_a_len_std","res_a_len_eff_mean
","p_a_sum_diff","p_a_mean_diff","p_a_max_diff","p_a_med_diff","p_a_eff_mean_diff
","res_b_len_sum","res_b_len_mean","res_b_len_max","res_b_len_sum_log","res_b_len
_mean_log","res_b_len_max_log","res_b_len_med","res_b_len_std","res_b_len_eff_mea
n","p_b_sum_diff","p_b_mean_diff","p_b_max_diff","p_b_med_diff","p_b_eff_mean_dif
f"]
```

Preprocessing

预处理器获取输入字符串并将其转换为包含预处理张量的字典 (token_ids、padding_mask)。

- 这个过程从分词开始，将输入字符串转换为标记 ID 序列。

```
preprocessor = keras_nlp.models.DebertaV3Preprocessor.from_preset(
 preset=CFG.preset,
 sequence_length=CFG.sequence_length,
)
```

AWP

AWP（Adversarial Weight Perturbation）是一种提高模型鲁棒性和泛化能力的技术，通过在训练过程中对模型权重添加扰动，使模型在面对对抗性输入时表现更好。下面是代码中 AWP 的具体实现和作用解析：

```
# 定义 AWP 扰动函数
def awp_perturb(model, epsilon=1e-4):
    for layer in model.layers:
        if hasattr(layer, 'kernel'):
            # 获取权重
            weights = layer.kernel
            # 计算扰动
            perturbation = tf.random.normal(weights.shape, stddev=epsilon)
            # 应用扰动
            layer.kernel.assign_add(perturbation)
```

这个函数的作用是对模型的每一层添加小的随机扰动：

1. **遍历模型的每一层**：通过 `for layer in model.layers` 遍历模型的所有层。
2. **检查是否具有 `kernel` 属性**：通过 `hasattr(layer, 'kernel')` 检查该层是否有权重（`kernel`），即只有对包含权重的层添加扰动。
3. **获取权重**：将层的权重赋值给 `weights`。
4. **计算扰动**：使用 `tf.random.normal(weights.shape, stddev=epsilon)` 生成与权重形状相同的随机扰动，标准差为 `epsilon`。
5. **应用扰动**：通过 `layer.kernel.assign_add(perturbation)` 将扰动加到权重上。

```
# 创建 AWP 回调函数
class AWPCallback(keras.callbacks.Callback):
    def __init__(self, epsilon):
        super(AWPCallback, self).__init__()
        self.epsilon = epsilon

    def on_batch_begin(self, batch, logs=None):
        # 在每个批次开始时应用 AWP 扰动
        awp_perturb(self.model, self.epsilon)
```

这个回调函数的作用是在每个训练批次开始时应用 AWP 扰动：

1. **初始化 `epsilon` 参数**：通过 `__init__` 方法设置扰动的标准差 `epsilon`。
2. **在批次开始时应用扰动**：通过重写 `on_batch_begin` 方法，在每个训练批次开始时调用 `awp_perturb` 函数对模型添加扰动。

> 通过这种方式，AWP 在训练过程中不断对模型权重添加小的随机扰动，迫使模型在权重空间中寻找更加鲁棒的解，从而提高模型对对抗性输入的抵抗能力和泛化性能。

DataLoader

使用 tf.data.Dataset 为数据处理建立了一个强大的数据流管道。

> 整体流程
>
> 1. **创建切片**：根据输入文本、标签和特征创建数据切片。
> 2. **创建数据集**：从切片中创建 TensorFlow 数据集。
> 3. **缓存数据集**：根据需要缓存数据集。
> 4. **预处理数据**：使用预处理函数对数据进行处理。
> 5. **打乱数据集**：根据需要打乱数据集。
> 6. **批处理和预取**：按批次处理数据并预取数据。
> 7. **返回数据集**：返回处理好的数据集。

```
def build_dataset_with_features(texts, labels=None, features_a=None,
features_b=None, batch_size=32, cache=True, shuffle=1024):
    AUTO = tf.data.AUTOTUNE
    if (features_a is not None) and (features_b is not None):
        slices = (texts, None, features_a, features_b) if labels is None else
(texts, keras.utils.to_categorical(labels, num_classes=3), features_a,
features_b)  # Create slices
    else:
        slices = (texts,) if labels is None else (texts,
keras.utils.to_categorical(labels, num_classes=3))  # Create slices
    ds = tf.data.Dataset.from_tensor_slices(slices)
    ds = ds.cache() if cache else ds
    ds = ds.map(preprocess_fn, num_parallel_calls=AUTO)
    opt = tf.data.Options()
    if shuffle:
        ds = ds.shuffle(shuffle, seed=CFG.seed)
        opt.experimental_deterministic = False
    ds = ds.with_options(opt)
    ds = ds.batch(batch_size, drop_remainder=False)
```

```
    # drop_remainder=False 表示在进行批处理时不会丢弃不完整的最后一个批次。
    ds = ds.prefetch(AUTO)

    return ds
```

Model

```
with strategy.scope():

    # 将所有输入层整合到一个字典中
    inputs = {
        "token_ids": keras.layers.Input(shape=(2, None), dtype=tf.int32,
name="token_ids"),
        "padding_mask": keras.layers.Input(shape=(2, None), dtype=tf.int32,
name="padding_mask"),
        "features_a": keras.layers.Input(shape=(14,), name="features_a",
dtype=tf.float32),
        "features_b": keras.layers.Input(shape=(14,), name="features_b",
dtype=tf.float32),
    }

    # Create a DebertaV3Classifier backbone
    backbone = keras_nlp.models.DebertaV3Backbone.from_preset(
        CFG.preset,
    )

   # 修改 response_a 和 response_b 的创建方式，包含 padding_mask
    response_a = {
        "token_ids": inputs["token_ids"][:, 0, :],
        "padding_mask": inputs["padding_mask"][:, 0, :]
    }
    embed_a = backbone(response_a)

    response_b = {
        "token_ids": inputs["token_ids"][:, 1, :],
        "padding_mask": inputs["padding_mask"][:, 1, :]
    }
    embed_b = backbone(response_b)

    # 将数值特征嵌入
    len_features_a_embedding = keras.layers.Dense(512, activation='relu')
(inputs["features_a"])
    len_features_b_embedding = keras.layers.Dense(512, activation='relu')
(inputs["features_b"])

    # 使用 Flatten 层将数值特征嵌入展平为二维张量
    flattened_len_features_a = keras.layers.Flatten()(len_features_a_embedding)
    flattened_len_features_b = keras.layers.Flatten()(len_features_b_embedding)

    embed_a = keras.layers.GlobalAveragePooling1D()(embed_a)
    embed_b = keras.layers.GlobalAveragePooling1D()(embed_b)
    embeds_text_features_a = keras.layers.Concatenate(axis=-1)([embed_a,
flattened_len_features_a])
    embeds_text_features_b = keras.layers.Concatenate(axis=-1)([embed_b,
flattened_len_features_b])
```

```
#     # 合并文本嵌入和数值特征嵌入
    combined_embeds = keras.layers.Concatenate(axis=-1)([embeds_text_features_a,
embeds_text_features_a])

    # 定义 temperature_scale 函数
    def temperature_scale(logits, T=1.0):
        return logits / T

    # 定义温度参数 T
    T = 0.85  # 这个值可以根据需要调整
    # 应用温度缩放
    scaled_logits = temperature_scale(combined_embeds, T)

    outputs = keras.layers.Dense(3, activation="softmax", name="classifier")
(scaled_logits)

    model = keras.Model(inputs,  outputs)

    # Compile the model with optimizer, loss, and metrics
    model.compile(
        optimizer=keras.optimizers.Adam(learning_rate=1e-6, clipnorm=1.0),
        loss=keras.losses.CategoricalCrossentropy(label_smoothing=0.1,
from_logits=False),
        metrics=[
            log_loss,
            keras.metrics.CategoricalAccuracy(name="accuracy"),
        ],
    )
```

模型的层级视图

Layer (type)	Output Shape	Param #	Connected to
padding_mask (InputLayer)	(None, 2, None)	0	-
token_ids (InputLayer)	(None, 2, None)	0	-
get_item_1 (GetItem)	(None, None)	0	padding_mask[0][…
get_item (GetItem)	(None, None)	0	token_ids[0][0]
features_a (InputLayer)	(None, 14)	0	-
deberta_v3_backbone (DebertaV3Backbone)	(None, None, 384)	70,682,112	get_item_1[0][0], get_item[0][0]
dense (Dense)	(None, 512)	7,680	features_a[0][0]
global_average_poo… (GlobalAveragePool…	(None, 384)	0	deberta_v3_backb…
flatten (Flatten)	(None, 512)	0	dense[0][0]
concatenate (Concatenate)	(None, 896)	0	global_average_p… flatten[0][0]
concatenate_2 (Concatenate)	(None, 1792)	0	concatenate[0][0… concatenate[0][0]
dense_2 (Dense)	(None, 256)	459,008	concatenate_2[0]…
dropout_12 (Dropout)	(None, 256)	0	dense_2[0][0]
true_divide (TrueDivide)	(None, 256)	0	dropout_12[0][0]
features_b (InputLayer)	(None, 14)	0	-
classifier (Dense)	(None, 3)	771	true_divide[0][0]

Total params: 71,149,571 (271.41 MB)

输入层:

- `token_ids` 和 `padding_mask` 是模型的文本输入，形状为 `(2, None)`，没有参数（0）。
- `features_a` 和 `features_b` 是数值特征的输入，形状为 `(14,)`，也没有参数（0）。

DebertaV3 主干网络:

- `deberta_v3_backbone` 是从 `token_ids` 和 `padding_mask` 输入生成的文本嵌入部分，输出形状为 `(None, None, 384)`，有约 70,682,112 个参数。

数值特征嵌入和展平:

- `dense` 层将 `features_a` 嵌入到 `(None, 512)` 的形状，有 7,680 个参数。
- `flatten` 层将其展平为 `(None, 512)`，没有额外参数。

文本嵌入池化和特征合并:

- `global_average_pooling1d` 对文本嵌入进行池化操作，输出形状为 `(None, 384)`，没有参数。
- `concatenate` 将文本嵌入与展平的数值特征合并，形状为 `(None, 896)`，没有额外参数。

> **特征合并和正则化**：
>
> - `concatenate_2` 将前面合并的特征再次合并，形状为 `(None, 1792)`，没有额外参数。
> - `dense_2` 添加了 459,008 个参数的 `Dense` 层，形状为 `(None, 256)`。
> - `dropout_12` 是一个丢弃率为 0.5 的 `Dropout` 层，没有额外参数。
>
> **温度缩放和输出层**：
>
> - `true_divide` 对 `dense_2` 的输出进行温度缩放，形状保持 `(None, 256)`，没有额外参数。
> - `classifier` 是最终的输出层，输出形状为 `(None, 3)`，有 771 个参数。

Training

```
try:
    history = model.fit(
        train_ds,
        epochs=CFG.epochs,
        validation_data=valid_ds,
        callbacks=[lr_cb, ckpt_cb, awp_cb]  # 将 AWP 回调添加到训练回调列表中
    )
except tf.errors.InvalidArgumentError as e:
    print(f"出现无效参数错误: {e}")
```